

《现代数据库系统概论》期末大作业

王崧尧*

汇报日期：2026 年 6 月 11 日 (Week 16) 截止日期：2026 年 6 月 13 日

1 引言

作业以小组形式完成，每组最多 4 人。各位同学需从三个选题方向中选择一个方向完成作业，每个选题方向最多允许 3 个小组参与，按报名链接¹填写顺序先到先得，以保证各方向组数均衡。

每个选题包含必做部分和选做部分（括号标注）。必做部分共 70 分；选做部分同学可根据兴趣自由选择，不作强制要求，单项上限均为 30 分（依完成质量评定），多项均可完成，总分以 100 分为上限。注意：大作业的得分还会参考线下汇报过程中问答的表现。

请仔细阅读 Section 2 至 Section 4 中的具体选题内容，明确任务和实验要求后，再完成组队并选题。

2 选题 1：社区发现与社区搜索

本选题聚焦于社区发现（Community Detection）和社区搜索（Community Search）问题，旨在识别图结构中紧密关联的节点群体。社区结构广泛存在于社交网络、学术引用网络、在线交易网络、交通网络等实际场景中，有助于研究人员理解群体行为、信息传播模式及关键节点影响力。例如，社交平台可利用社区发现算法识别兴趣群体并推荐相关内容；科研人员可通过在合作网络中执行社区搜索，识别学术合作集群，从而优化资源分配与合作策略。

请同学们完成如下任务：

1. [20 分] 独立调研社区发现与社区搜索领域的文献，构建多维度的科学分类体系。
2. [20 分] 从给定的 11 篇论文 [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11] 中选择 1 篇进行算法复现。
3. [15 分] 自行选择论文中的 3-4 组数据集运行实验，统计社区发现或社区搜索的运行时间及社区质量等关键指标（社区质量衡量指标可自行选择）。
4. [15 分] 使用经典社区发现或社区搜索算法（如 Louvain [12]）在相同数据集上运行实验，汇报运行时间及社区质量指标，并与复现算法进行对比分析。
5. (选做) 思考图结构随时间演化（节点和边的插入与删除）时社区结构的变化，提出相应方法，并尝试在动态图中发现高质量社区结构。

*wangsong23@mails.tsinghua.edu.cn

¹<https://docs.qq.com/sheet/DU0tvbWNmeXFmdm9U?tab=BB08J2>

3 选题 2: 子图匹配

子图匹配问题定义如下: 给定数据图 $G = (V_G, E_G, \ell_G)$ 和查询图 $Q = (V_Q, E_Q, \ell_Q)$, 其中 V_G, V_Q 为顶点集合, E_G, E_Q 为边集合, ℓ_G, ℓ_Q 为顶点标签函数。子图匹配要求找到一个单射 $f: V_Q \rightarrow V_G$, 满足 $\forall v \in V_Q, \ell_Q(v) = \ell_G(f(v))$ 且 $\forall (u, v) \in E_Q, (f(u), f(v)) \in E_G$, 即查询图在数据图中存在结构和标签完全匹配的子图。

在实际应用中, 子图匹配广泛用于社交网络分析、金融交易异常检测、知识图谱查询及生物网络分析等场景。在图数据库管理系统中, 子图匹配是复杂图查询处理的核心, 匹配算法的效率直接影响数据库的查询性能。

请同学们完成如下任务:

1. [15 分] 独立调研子图匹配领域的文献, 构建多维度的科学分类体系。
2. [20 分] 从给定的论文集合 [13, 14, 15, 16, 17] 中选择 1 篇进行复现。
3. [20 分] 自行选择论文中的 3-4 组数据集运行实验, 统计: 运行时间、最终 result mapping 数量、产生的 partial mapping 数量, 以及论文所提过滤策略过滤掉的 partial mapping 数量。
4. [15 分] 依次关闭论文中提到的各过滤策略, 分别统计运行时间和 partial mapping 数量, 分析各策略的贡献。
5. (选做) 思考子图匹配结果的可复用性, 探讨后续查询能否利用先前查询的结果, 并基于此设计优化算法。
6. (选做) 图结构变化时 (插入或删除一条边), 设计算法动态维护 result mapping, 找出因该变化导致的结果差异。
7. (选做) 子图同态算法的设计与实现。本作业中, 子图同态定义如下:

给定数据图 $G = (V_G, E_G, \ell_G)$ 和查询图 $Q = (V_Q, E_Q, \ell_Q)$, 子图同态要求找到一个映射

$$f: V_Q \rightarrow V_G$$

满足以下条件:

- (a) 标签约束: $\forall v \in V_Q, \ell_Q(v) = \ell_G(f(v))$;
- (b) 边约束: $\forall (u, v) \in E_Q$, 有 $(f(u), f(v)) \in E_G^+$, 其中 $E_G^+ = E_G \cup \{(w, w) \mid w \in V_G\}$;
- (c) 映射可重用性: f 不要求为单射, 即允许多个查询顶点映射到同一数据顶点。

此定义在保持顶点标签一致性和边结构约束的同时, 允许多个查询顶点映射到同一数据顶点; 当多个查询顶点折叠至同一数据顶点时, 其关联边映射为自环, 由 E_G^+ 统一处理, 不产生冲突。

4 选题 3: 向量数据管理

近似最近邻索引 (Approximate Nearest Neighbor Index, ANN Index) 是一类用于高维向量空间中快速检索最相似对象的数据结构与算法。它通过牺牲少量精度换取大幅提升的查询速度, 广泛应用于推荐系统、图像/文本检索、语义搜索、知识库问答及生物信息比对等场景。在处理大规模高维数据时, ANN 索引能够显著提升查询吞吐量, 是现代人工智能与大数据系统中不可或缺的基础组件。

请同学们完成如下任务:

1. [15 分] 独立调研 ANN Index 领域的文献, 构建多维度的科学分类体系。
2. [25 分] 复现 DiskANN [18]。
3. [15 分] 选择 3-4 个数据集运行实验, 统计 KNN 查询的吞吐量 (QPS) 和召回率; 并在不同召回率约束下 (如 90%、95%、99%), 分别汇报对应的 QPS。
4. [10 分] 使用 HNSW [19] 在相同数据集上运行实验, 统计吞吐量和召回率, 并与 DiskANN 进行对比。
5. [5 分] 对比 HNSW 与 DiskANN 搜索过程中访问邻居的次数, 并结合实验结果解释一下, DiskANN 提出 Vamana Graph 的动机。
6. (选做) HNSW 支持向量的插入与删除, 思考如何为 DiskANN 添加相同支持, 设计实验测试插入和删除操作的吞吐量。
7. (选做) 给定向量集合 $V = \{v_1, v_2, \dots, v_n\}$ 和阈值 $\varepsilon > 0$, 找到所有满足 $\text{dist}(v_i, v_j) < \varepsilon$ 的向量对 (v_i, v_j) ; 思考在数据规模超出内存容量时的高性能实现方式。

5 提交要求

1. **实验报告:** 使用指定 L^AT_EX 模板 [20] 撰写英文报告, 须包含以下内容 (建议每条对应一个 Section):
 - (a) 选题背景简介;
 - (b) 文献调研报告;
 - (c) 复现论文的算法思路;
 - (d) 实验结果与分析;
 - (e) 选做项 (若完成): 思路、算法实现及实验结果;
 - (f) 总结, 包括选题发展历史及个人心得;
 - (g) 组内分工说明。

严禁使用 AI 生成图片; 引用外部图片须标注来源; 自制图片推荐使用 PPT 或其他矢量绘图工具 (如 draw.io) 绘制, 并提交对应源文件; 实验结果图须附带绘图源代码 (Python、GnuPlot 等)。

鼓励同学们在报告中说明必做以外的任何加分项。同学亦可自行设计创意加分项，本文所列选做仅为获取加分的途径之一；完成后请在报告中写清楚加分项的思路、算法实现及实验结果。

2. **源代码**：附带所用数据集；数据集过大可上传至云盘，并在报告中提供下载链接。代码须写清楚复现步骤。
3. **汇报 PPT**：每组 5-7 分钟汇报，3-5 分钟提问，总时长不超过 10 分钟。
4. **关于 AI 使用**：严禁使用任何 AI 工具直接生成实现代码。如使用 AI 编程辅助工具（如 Claude Code、GitHub Copilot、Cursor 等），须提供完整的 Prompt 或对话记录。

参考文献

- [1] A. Mahmood and M. Small, “Subspace based network community detection using sparse linear coding,” in *2016 IEEE 32nd International Conference on Data Engineering (ICDE)*, 2016, pp. 1502–1503.
- [2] A. Epasto, S. Lattanzi, V. Mirrokni, I. O. Sebe, A. Taei, and S. Verma, “Ego-net community mining applied to friend suggestion,” *Proc. VLDB Endow.*, vol. 9, no. 4, p. 324–335, Dec. 2015. [Online]. Available: <https://doi.org/10.14778/2856318.2856327>
- [3] S. Lim, J. Kim, and J.-G. Lee, “Blackhole: Robust community detection inspired by graph drawing,” in *2016 IEEE 32nd International Conference on Data Engineering (ICDE)*, 2016, pp. 25–36.
- [4] J. Kim, S. Lim, J.-G. Lee, and B. Lee, “Linkblackhole*: Robust overlapping community detection using link embedding,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 31, no. 11, pp. 2138–2150, 2019.
- [5] H. Van Lierde, T. W. S. Chow, and G. Chen, “Scalable spectral clustering for overlapping community detection in large-scale networks,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 32, no. 4, pp. 754–767, 2020.
- [6] Y. Fang, Y. Yang, W. Zhang, X. Lin, and X. Cao, “Effective and efficient community search over large heterogeneous information networks,” *Proc. VLDB Endow.*, vol. 13, no. 6, p. 854–867, Feb. 2020. [Online]. Available: <https://doi.org/10.14778/3380750.3380756>
- [7] Q. Liu, M. Zhao, X. Huang, J. Xu, and Y. Gao, “Truss-based community search over large directed graphs,” in *Proceedings of the 2020 ACM SIGMOD International Conference on Management of Data*, ser. SIGMOD ’20. New York, NY, USA: Association for Computing Machinery, 2020, p. 2183–2197. [Online]. Available: <https://doi.org/10.1145/3318464.3380587>

- [8] J. Luo, X. Cao, X. Xie, Q. Qu, Z. Xu, and C. S. Jensen, “Efficient attribute-constrained co-located community search,” in *2020 IEEE 36th International Conference on Data Engineering (ICDE)*, 2020, pp. 1201–1212.
- [9] Q. Liu, Y. Zhu, M. Zhao, X. Huang, J. Xu, and Y. Gao, “Vac: Vertex-centric attributed community search,” in *2020 IEEE 36th International Conference on Data Engineering (ICDE)*, 2020, pp. 937–948.
- [10] R.-H. Li, J. Su, L. Qin, J. X. Yu, and Q. Dai, “Persistent community search in temporal networks,” in *2018 IEEE 34th International Conference on Data Engineering (ICDE)*, 2018, pp. 797–808.
- [11] Z. Dong, X. Huang, G. Yuan, H. Zhu, and H. Xiong, “Butterfly-core community search over labeled graphs,” *Proc. VLDB Endow.*, vol. 14, no. 11, p. 2006–2018, Jul. 2021. [Online]. Available: <https://doi.org/10.14778/3476249.3476258>
- [12] V. D. Blondel, J.-L. Guillaume, R. Lambiotte, and E. Lefebvre, “Fast unfolding of communities in large networks,” *Journal of Statistical Mechanics: Theory and Experiment*, vol. 2008, no. 10, p. P10008, oct 2008. [Online]. Available: <https://dx.doi.org/10.1088/1742-5468/2008/10/P10008>
- [13] M. Han, H. Kim, G. Gu, K. Park, and W.-S. Han, “Efficient subgraph matching: Harmonizing dynamic programming, adaptive matching order, and failing set together,” in *Proceedings of the 2019 International Conference on Management of Data*, ser. SIGMOD ’19. New York, NY, USA: Association for Computing Machinery, 2019, p. 1429–1446. [Online]. Available: <https://doi.org/10.1145/3299869.3319880>
- [14] J. Arai, Y. Fujiwara, and M. Onizuka, “Gup: Fast subgraph matching by guard-based pruning,” *Proc. ACM Manag. Data*, vol. 1, no. 2, Jun. 2023. [Online]. Available: <https://doi.org/10.1145/3589312>
- [15] Z. Zhang and W. Zheng, “Bee: Towards redundancy reduction via block-separator decomposition for subgraph matching,” *Proc. ACM Manag. Data*, vol. 3, no. 4, Sep. 2025. [Online]. Available: <https://doi.org/10.1145/3749159>
- [16] B. Bhattarai, H. Liu, and H. H. Huang, “Ceci: Compact embedding cluster index for scalable subgraph matching,” in *Proceedings of the 2019 International Conference on Management of Data*, ser. SIGMOD ’19. New York, NY, USA: Association for Computing Machinery, 2019, p. 1447–1462. [Online]. Available: <https://doi.org/10.1145/3299869.3300086>
- [17] V. Carletti, P. Foggia, A. Saggese, and M. Vento, “Challenging the time complexity of exact subgraph isomorphism for huge and dense graphs with vf3,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 40, no. 4, pp. 804–818, 2018.

- [18] S. Jayaram Subramanya, F. Devvrit, H. V. Simhadri, R. Krishnawamy, and R. Kadekodi, “Diskann: Fast accurate billion-point nearest neighbor search on a single node,” in *Advances in Neural Information Processing Systems*, H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, Eds., vol. 32. Curran Associates, Inc., 2019. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2019/file/09853c7fb1d3f8ee67a61b6bf4a7f8e6-Paper.pdf
- [19] Y. A. Malkov and D. A. Yashunin, “Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs,” 2018. [Online]. Available: <https://arxiv.org/abs/1603.09320>
- [20] Overleaf, “Acm journals primary article template,” <https://www.overleaf.com/latex/templates/acm-journals-primary-article-template/cpkjqttwbshg>, accessed: 2026-05-14.